扩散式视觉导航中的方向引导改进

全局目标定位 × 短时航点预测

基于 NoMaD 与 DINOv2 的
不确定性感知目标定位研究

NoMaD

DINOv2

置信度加权融合



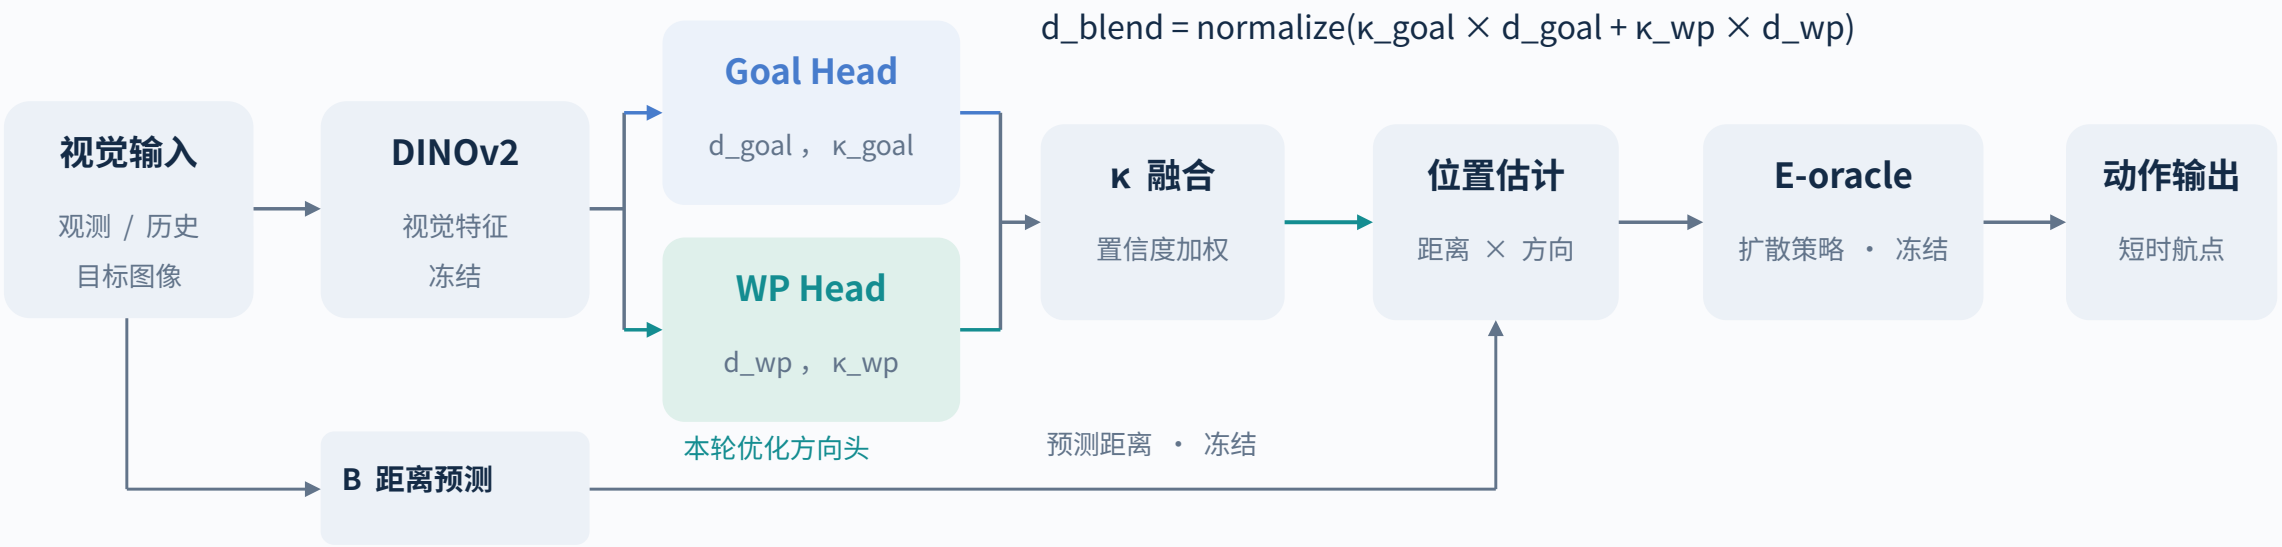
如何用远程目标，引导短时导航动作?

全局目标方位：目标在哪里

远程定位信息，未必与当前可行路径一致

局部航点方向：未来 8 步往哪里走

短时路径信息，急转弯时可能出现严重预测误差



核心思路：保持主策略冻结，改善方向引导，再检验下游条件收益。

评估： use_cm = 100 × (ADE_masked − ADE_conditioned)；越大越好，不等同于导航成功率

主要损失来自目标方位，还是航点方向?

锁定远目标 1,000 帧 · 固定 B 预测距离与 E-oracle 策略 · 仅替换方向输入

2 × 2 方向替换实验

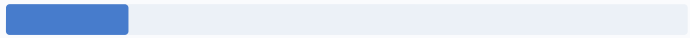
	预测 WP	真实 WP
预测 Goal	2.62 当前预测组合	4.66 仅替换 WP
真实 Goal	2.99 仅替换 Goal	5.03 同时替换两者

数值：目标条件收益 use_cm （cm），越大越好

相对预测组合，能恢复多少收益?

同一基线：预测 Goal + 预测 WP = 2.62 cm

仅将 Goal 替换为真实方向



+0.37 cm

仅将 WP 替换为真实方向



+2.04 cm

真实 WP 使用未来轨迹信息，
仅用于离线 Oracle 分析，部署时不可用。

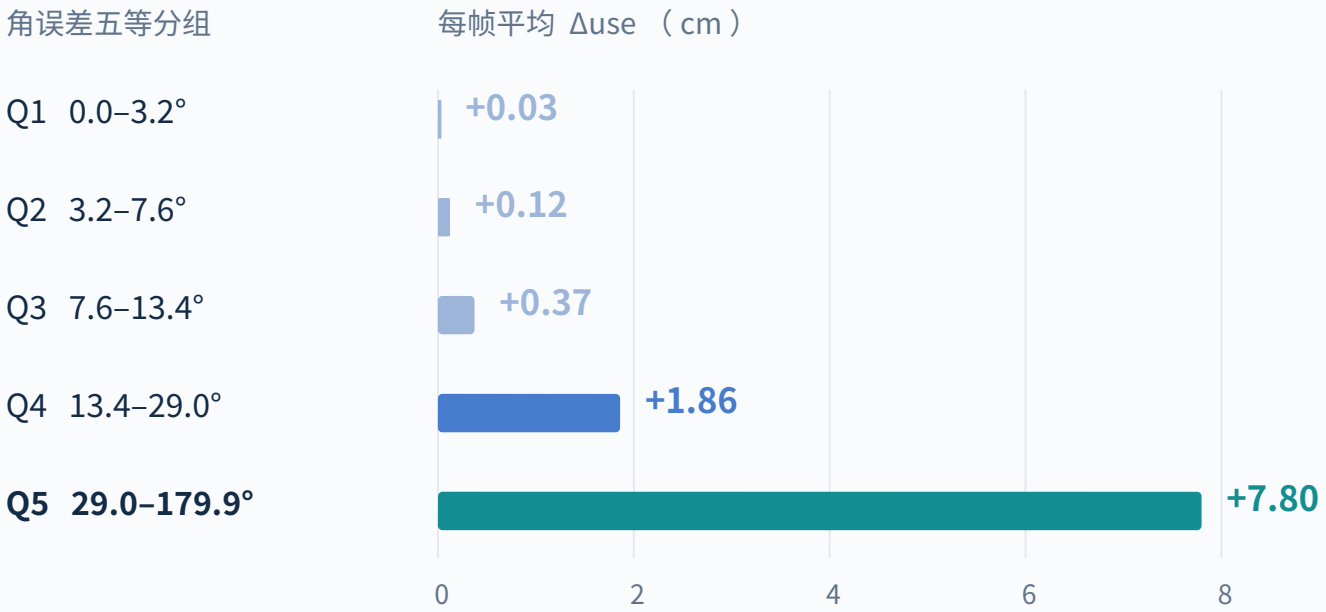
结论：在当前融合与策略设定下，航点方向具有更大的可恢复收益空间。

来源： oracle_factorial/factorial_use.csv · all, n=1000； Oracle 收益不等同于可部署改进。

哪些样本贡献了大部分 Oracle 收益?

锁定远目标 1,000 帧 · 仅将预测 WP 方向替换为真实方向 · 其余条件保持不变

WP 角误差越大，替换真实方向的平均收益越高



每组 200 帧；最高误差组 Q5 贡献 76.6% 的净收益。

r = 0.623 角误差与收益

Pearson 相关；相关性不代表因果。

68.9% 正收益集中度

收益最高的 10% 帧，占全部正收益的 68.9%。

88.1% 严格转弯贡献

严格转弯 593 帧，占全部净收益的 88.1%。

结论：损失集中于严重航点方向错误，下一步应优先分析转弯难例。

来源： wp_oracle_attribution/ 下的 summary.txt 、 by_wp_err_quintile.csv 、 turn_vs_straight.csv

转弯比例相近时，难例还有什么特点?

承接上一页：严重错误集中在转弯场景；这里进一步比较困难帧与非困难帧的运动特征。

困难组： 120 帧

WP 方向误差 ⩾ 45°；其中严格转弯占 93.3%。

对照组：从非困难帧中选取

匹配转弯占比为 93.3%，减少弯道与直道差异的影响。

① 未来路径更弯

未来 8 步累计绝对转角（中位数）



每步转了多少角度，取绝对值后累加。

② 近期旋转更强

历史平均步间转角（中位数）



过去 3 步绝对航向变化的均值。

这些是组间相关特征；对照只匹配了转弯比例，尚不能证明近期旋转或路径弯曲导致预测错误。

下一步假设：既然难例伴随更强的近期旋转，就检验视觉历史能否帮助方向预测。

来源： wp_hard120/summary.txt 、 enrichment_H_vs_control.csv （C_match）；两图按各自指标独立定标。

引入视觉历史，能否改善转弯方向预测?

冻结 NoMaD 、 DINOv2 与扩散策略 · 比较无历史对照 ctx0 与两帧历史 ctx2

干预：仅增加 WP 头的历史输入

ctx0 / ctx2 ： 相同初始化与训练预算



目标图像输入保持一致

e60 ： 原始 WP 基线； ctx0 ： 无历史续训对照。

方向误差与下游条件收益分别评估

模型 / 指标	e60	ctx0	ctx2
验证集 Val · 5,110 远目标帧 · 误差越低越好 ↓			
全量中位角误差	8.58°	8.50°	**7.97°**
转弯角误差 P90	57.84°	59.80°	**53.12°**
转弯大误差占比 >45°	14.5%	14.9%	**12.6%**
Locked · 固定 1,000 远目标帧 · 条件收益越高越好 ↑			
κ 融合 use_cm	**+2.56**	**+2.68**	**+2.80**

结论：两帧视觉历史同时改善方向误差与条件收益；下游增益仍需配对统计验证。

来源： P2_protocol.md 、 P2_conclusions_revised.md 、 p2_val_bearing/summary.txt ； use 单位 cm ，非成功率。

提高转弯样本权重，能否减少尾部错误?

单样本方向损失不变；在原有距离权重上，再乘转弯权重，让难例对训练影响更大。

原来：仅按目标距离加权

$$L_{原} = \frac{\sum_i b_i \ell_i}{\sum_i b_i}$$

现在：距离权重 × 转弯权重

$$L_{新} = \frac{\sum_i b_i \alpha_i \ell_i}{\sum_i b_i \alpha_i}$$

ℓ_i：单样本方向损失； b_i：原有目标距离权重； α_i：本次新增的转弯权重。

B：转弯 $\alpha=2$； C：转弯 $\alpha=3$（其他样本均为 1）； D：累计转角低 / 中 / 高三档 $\alpha=1 / 1.5 / 3$。

ℓ_i 的计算：预热时 $1-\cos\theta_i$；后续为 $-\kappa_i \cos\theta_i + \log I_0(\kappa_i)$（$\theta_i$ 为方向误差， κ_i 为方向集中度）。

WP 训练方案	全量中位误差 ↓	转弯中位误差 ↓	转弯 P90 ↓	全量 >45° 占比 ↓
ctx2 ｜仅原有距离权重	**7.97°**	**13.02°**	**53.12°**	**7.08%**
B ｜严格转弯 ×2	8.04°	**12.11°**	55.77°	8.04%
C ｜严格转弯 ×3	8.11°	**12.55°**	54.01°	7.44%
D ｜累计转角分档 1 / 1.5 / 3	8.07°	**11.98°**	53.95°	7.75%

仅训练时增加 α；验证时取消额外转弯加权。表中 >45° 比例的分母是全部 Val 远目标帧。

结论：转弯中位误差下降，但 P90 和全量大误差比例仍未优于 ctx2。

来源：train_goal_dino.py、train_goal_dir.py、P3_training_batch.md、p3_morning_metrics.csv；单次运行，尚需多种子验证。

增加辅助时域，能否带来更好的导航引导?

从 ctx2 初始化 · 额外训练 15 轮 · 加入第 2、4 步方向监督，保留第 8 步主目标

训练监督	2 步 · 辅助	4 步 · 辅助	8 步 · 主目标	推理保持不变：8 步方向 + κ

以下均为 ctx2 → P4；每组在相同评估集合内比较。

01 筛选 Val 子集

2/4 步位移 ≥ 0.3 m · 2,721 帧

中位角误差 ↓

7.11° → 6.30°

转弯 P90： 34.88° → 33.19°

子集内方向误差改善

02 完整 Val

full_5110 · 5,110 帧

转弯 P90 ↓

53.12° → 58.87°

中位角误差： 7.97° → 7.97°

尾部误差增大

03 Locked 下游评估

固定 1,000 远目标帧

κ 融合收益 ↑（cm）

2.80 → 2.40

无辅助监督续训 15 轮： 2.80 cm

未超过原模型与续训对照

补充： masked P4b 的完整 Val 中位误差降至 7.76°，但转弯 P90 为 54.41°，仍高于 ctx2 的 53.12°。

结论：筛选子集的改善未转化为完整 Val 尾部与下游收益的改善。

来源： P4_multi_horizon.md 、 P4_ablation_status.md 、 p4_ablation_val.txt；箭头均表示 ctx2 → P4 。

什么时候应该少信航点方向?

目标方向：目标在哪里 · 航点方向：接下来往哪里走 · 两者有时会相互冲突

原方法：根据两种预测的置信度，决定各自占多大比重。

我们尝试了什么?	结果怎么样?
01 看航点的权重占比，判断是否该少信它	效果变好与变差的样本，权重占比接近。
02 训练一个模型，判断是否该只用目标方向	判断能力接近随机猜测，未提高条件收益。
03 让模型自动降低航点的影响	模型几乎不作调整，效果接近原方法。
04 两种方向分歧大时，就减少航点权重	**条件收益从 2.80 降至 2.24 cm ，反而更差。**

说明：条件收益表示加入目标信息后误差减少了多少，越大越好；上述结果分别与各自的原方法比较。

其中部分模型使用了真实未来轨迹信息，仅为离线分析，尚不能直接用于实机。

启示：先把航点方向预测得更准，比继续增加这些判断规则更值得优先尝试。

来源： p5ab_summary.txt 、 p5b/c summary.json 、 kappa_fusion_summary.txt ； 技术细节与评估口径见备注。

继续优化航点训练，还能提高多少？

保持主策略与方向融合方式不变 · 只调整航点头的输入、监督与训练采样

训练思路：给转弯难例更大权重，或让困难样本在训练时更频繁地被抽到。

固定约 1,000 帧：条件收益（cm），越大越好

训练方案	全部远目标	严格转弯
两帧历史（原方案）	+2.80	+3.61
转弯难例组合加权	**+2.93**	**+3.91**
三帧历史（普通训练）	+2.84	+3.73
三帧历史 + 组合加权	+2.93	+3.92
组合加权 + 第 4/6 步辅助监督	+2.85	+3.79
组合加权 + 困难样本采样权重 ×3	**+2.94**	**+3.98**

“采样权重 ×3” 表示增加被抽中的相对机会；并非新采集三倍数据，也未证明已改善 Hard120 。

最高报告值： 2.94 cm

相比组合加权的 2.93 cm ，
仅多约 0.01 cm ，尚需重复验证。

收益略升，尾部未同步改善

困难采样后， WP 误差 >45°
占比约 11% ，组合加权约 10% 。

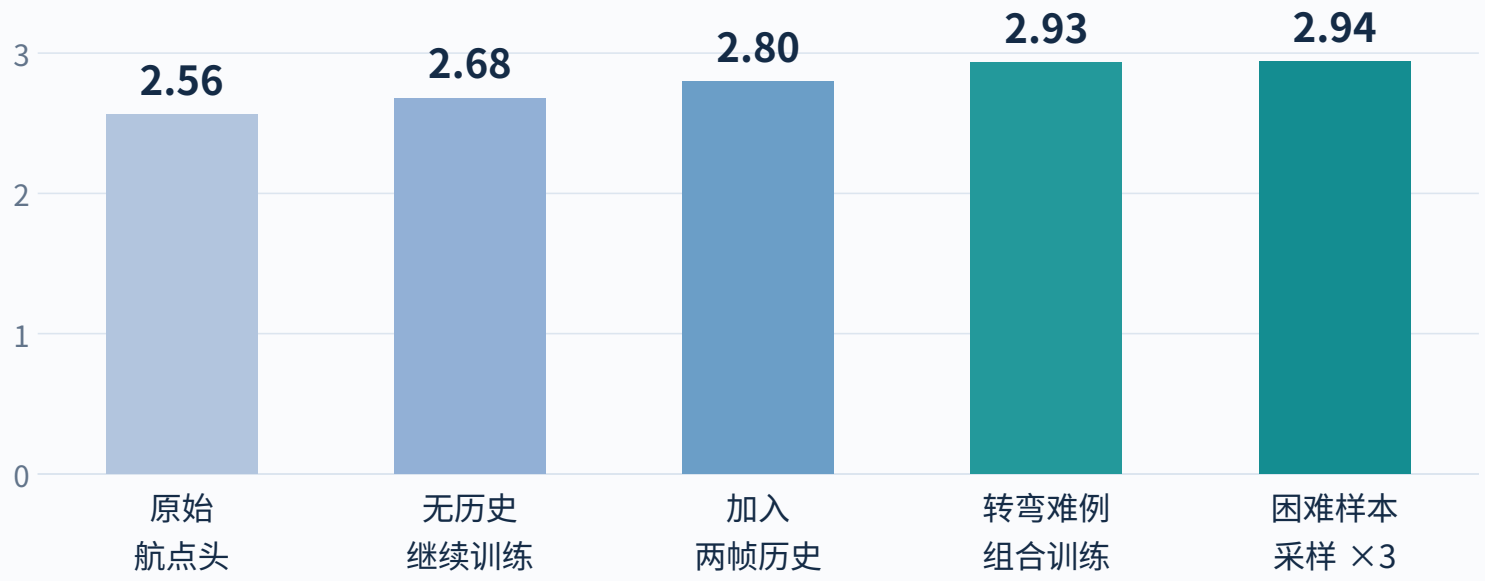
结论：转弯难例组合训练带来改善；继续加历史或调整采样，目前收益已很小。

来源： wp_input_sweep/ 、 wp_hard_oversample/ 、 wp_mh46/ ；两帧历史均指额外加入两帧过去观测。

这轮实验，整体取得了多少进展?

主策略与置信度融合方式保持不变 · 汇总各阶段固定远目标评估的条件收益

条件收益（cm）：越高，目标信息带来的帮助越大



+0.38 cm

从早期基线到最高报告值

2.56 → 2.94 cm： 条件收益的绝对增加。

约 14.8%

条件收益指标的相对增长

不等于导航成功率或整体精度提高 14.8% 。

约 +0.01 cm

最近一步的增幅已经很小

2.93 → 2.94 cm： 仍需重复实验确认。

说明：图按仓库汇总列示，纵轴从 0 开始；尚未用全部阶段的逐帧配对结果验证差异。

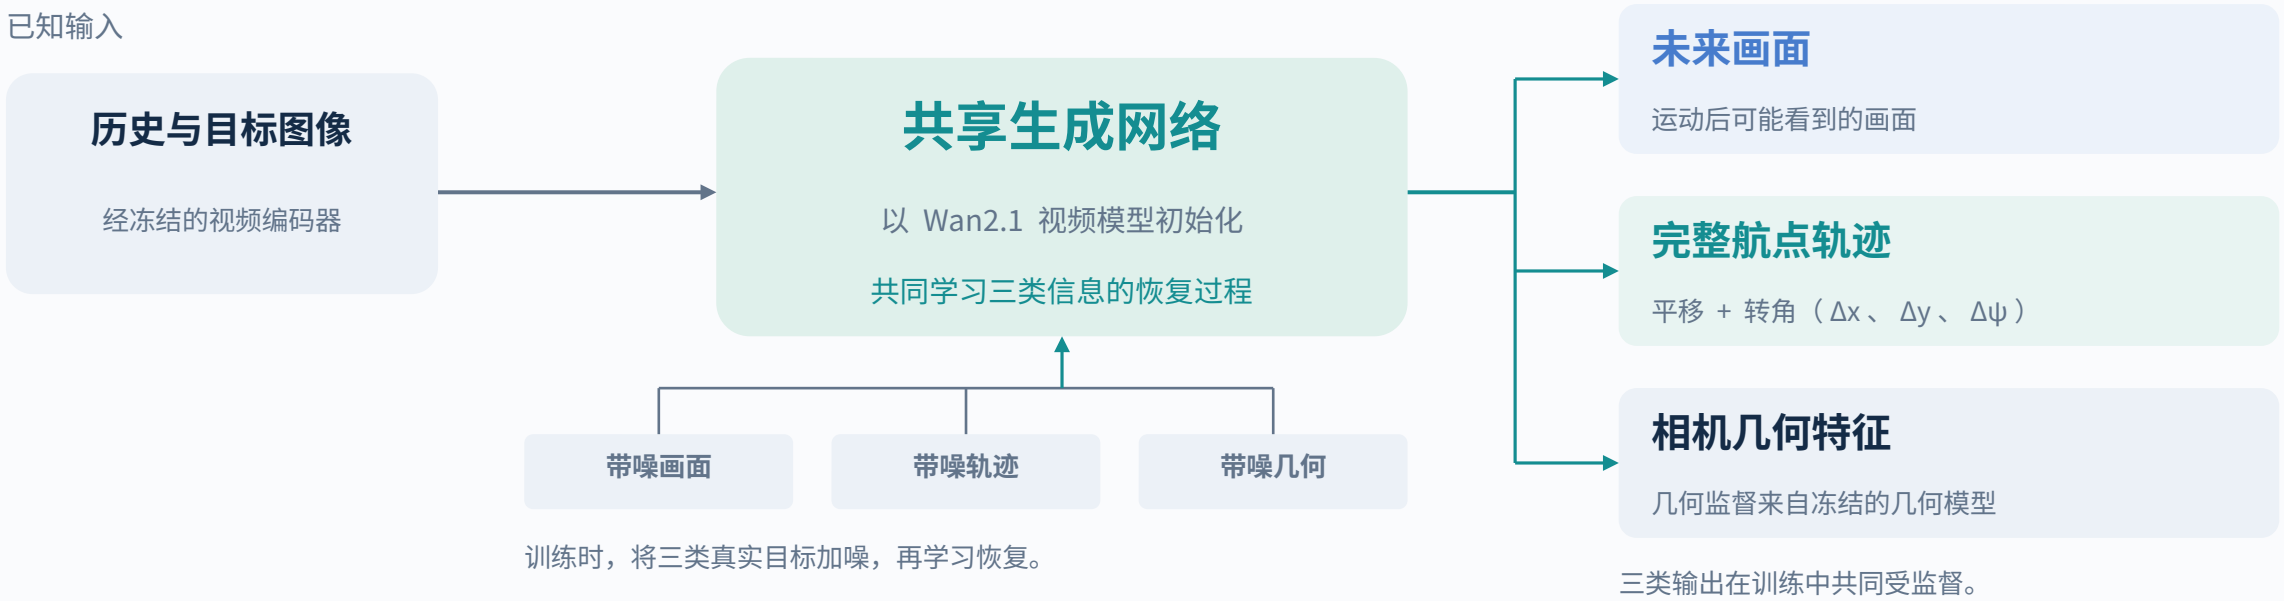
结论：主要进展来自视觉历史与航点训练；最新的小幅提升仍需要验证。

来源： README_report_index.md 、 P2_conclusions_revised.md 、 wp_input_sweep/ 、 wp_hard_oversample/ 。

同时学习“怎么走”和“走后会看到什么”

动机：只预测航点缺少视觉预见；为多条候选路线分别生成未来画面，又较耗时。

UniNav：将未来画面、航点轨迹与几何信息放进同一个生成模型



训练时，将三类真实目标加噪，再学习恢复。

三类输出在训练中共同受监督。

推理时未知量从噪声开始生成，不输入真实未来画面；轨迹同时预测平移与转角，并非只积分 yaw 。

借鉴思路：学习运动过程与视觉变化的联系，而不只预测一个终点方向。

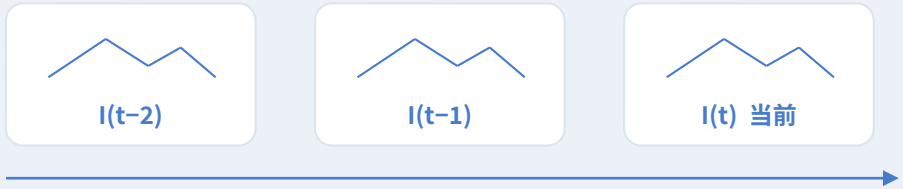
来源： UniNav， arXiv:2608.03244v1， §3.1–3.3、图 2；本页为中文简化重绘， Fast 设计另页说明。

模型看什么，又要生成什么?

以 UniNav-Full 默认设置为例：图像是视觉信息，航点是连续数值，不是轨迹图片。

输入：已知的历史与目标

3 帧历史观测，包含当前帧



RGB 图像 · 默认分辨率 256 × 192



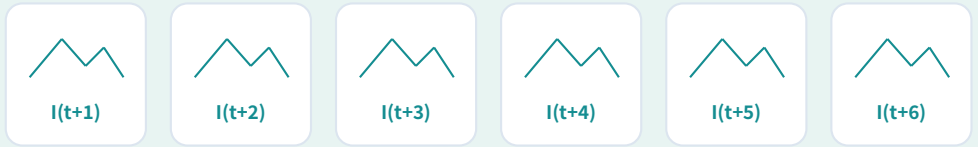
另外输入 1 张目标图像

表示目的地，不默认等于未来第 6 帧。

预测

输出：未来画面与运动轨迹

A | 6 帧未来 RGB 画面



B | 6 × 3 航点矩阵：每点 3 个量

点 1	Δx1	Δy1	Δψ1
点 2	Δx2	Δy2	Δψ2
点 3	Δx3	Δy3	Δψ3
点 4	Δx4	Δy4	Δψ4
点 5	Δx5	Δy5	Δψ5
点 6	Δx6	Δy6	Δψ6

Δx 、 Δy ： 平移

Δψ ： 航向变化

均在局部坐标系中描述

训练：真实未来画面与轨迹用于监督；推理：只给历史与目标，由模型生成未知未来。

来源： UniNav §3.1 、 §3.2 、 §4.1 ；图框为格式示意，矩阵仅示变量，不代表实验数值。

每类数据如何编码，又如何得到输出？

不同数据先变成可共同处理的向量；共享网络计算后，各输出头预测相应的去噪更新量。

原始数据	编码与映射（训练时）	共同计算	分支输出 → 最终结果
3 帧历史 +1 张目标 已知视觉条件	**冻结 VAE → 压缩特征 → 切块 / 嵌入** 历史、目标是已知条件； VAE 编码后保持为条件向量	**共享网络** **Transformer** 拼接向量序列 交换信息 更新共享特征 Wan2.1 初始化 主网络参与微调	**视频输出头 → 视觉特征更新量** 迭代恢复特征，再由 VAE 解码为 6 帧 RGB
6 帧未来画面 训练预测目标	**冻结 VAE → 特征加噪 → 切块 / 嵌入** 切块 = 把特征分组；嵌入 = 把每块映射到共享维度 D		
6 × 3 航点数值 训练预测目标	**数值加噪 → 小型映射网络 MLP** MLP= 全连接映射；每航点 3 维→ D 维，共 6 个		**轨迹输出头 → 6 × 3 更新量** 迭代后得到 6 × 3 的连续航点轨迹
历史 + 真实未来图像 训练几何教师的输入	**冻结 DA3 → 取未来几何特征 → 归一化** DA3： Depth Anything 3 （Lin 等， 2025） 特征加噪 → MLP ； 共 6 个未来几何向量		**几何输出头 → 几何特征更新量** 迭代后恢复未来视角的相机几何特征

VAE： 变分自编码器，编码压缩、解码重建。
来自 Wan （Wang 等， 2025），冻结使用。
向量维度 D： 每个 token 包含 D 个数字。

另加入可学习的寄存向量帮助信息交流；视觉向量保留时空位置编码，其余类型不强加图像网格位置。

参数更新： VAE 与 DA3 冻结；共享网络、新增 MLP 与输出头训练。更新量不是机器人速度。

来源： UniNav §3.2–3.3 ； Wan （2025）； DA3 （2025）。具体压缩尺寸、切块大小、 D 与几何维度未披露。

哪些结论已有支持，哪些还需要验证？

结合前面的消融与训练结果，明确目前的研究判断和证据边界

主要发现

01 航点方向是值得优先改善的环节

在当前方案中，替换真实航点方向的收益
明显高于替换真实目标方向。

02 少量严重错误集中了大部分改进空间

难例主要出现在转弯场景；
一般样本变好，并不代表严重错误减少。

03 视觉历史与针对性训练带来进展

继续增加历史帧数、辅助监督或复杂规则，
尚未持续超过当前较强的训练方案。

结论边界

真实方向只用于离线分析

真实航点包含未来轨迹信息，部署时拿不到；
分析中的潜在收益不等于实际可达到的改进。

条件收益不等于导航成功率

目前主要衡量目标信息能减少多少轨迹误差；
真实场景中能否更安全地到达目标，仍需验证。

小幅领先尚不能认定为可靠提升

2.93 与 2.94 cm 的差异很小；
还需重复训练、配对比较和独立测试。

适用范围：结论主要来自当前固定远目标评估；其他环境的泛化与实机表现，仍需进一步验证。

研究判断：除了远程目标定位，短时路径方向的质量也是关键改进空间。

依据：前述方向替换、难例归因、历史输入、转弯训练与融合规则实验；详细来源见备注。