每类数据如何编码，又如何得到输出？

不同数据先变成可共同处理的向量；共享网络计算后，各输出头预测相应的去噪更新量。

原始数据	编码与映射（训练时）	共同计算	分支输出 → 最终结果
3 帧历史 + 1 张目标 已知视觉条件	**冻结 VAE → 压缩特征 → 切块 / 嵌入** 得到历史、目标条件向量；不作为加噪目标	**共享网络** Transformer 拼接向量序列 交换信息 更新共享特征 主网络参与微调	历史与目标只作条件； 下方三支输出的是更新量。
6 帧未来画面 训练预测目标	**冻结 VAE → 特征加噪 → 切块 / 嵌入** 在压缩的视觉特征空间中加噪		**视频输出头 → 视觉特征更新量** 迭代恢复特征，再由 VAE 解码为 6 帧 RGB
6 × 3 航点数值 训练预测目标	**数值加噪 → 小型映射网络 MLP** 每个航点映射为 1 个向量，共 6 个		**轨迹输出头 → 6 × 3 更新量** 迭代后得到 6 × 3 的连续航点轨迹
历史 + 真实未来图像 训练几何教师的输入	**冻结 DA3 → 取未来几何特征 → 归一化** 特征加噪 → MLP；共 6 个未来几何向量		**几何输出头 → 几何特征更新量** 迭代后恢复未来视角的相机几何特征

另加入可学习的寄存向量帮助信息交流；视觉向量保留时空位置编码，其余类型不强加图像网格位置。

参数更新： VAE 与 DA3 冻结；共享网络、新增 MLP 与输出头训练。更新量不是机器人速度。

来源： UniNav §3.2–3.3、图 2；正文未给出视觉向量数量、隐藏维度及几何特征维度，本页不补造。