每类数据如何编码，又如何得到输出？

不同数据先变成可共同处理的向量；共享网络计算后，各输出头预测相应的去噪更新量。

原始数据	编码与映射（训练时）	共同计算	分支输出 → 最终结果
3 帧历史 + 1 张目标 已知视觉条件	**冻结 VAE → 压缩特征 → 切块 / 嵌入** 历史、目标是已知条件； VAE 编码后保持为条件向量	**共享网络** **Transformer** 拼接向量序列 交换信息 更新共享特征 Wan2.1 初始化 主网络参与微调	**视频输出头 → 视觉特征更新量** 迭代恢复特征，再由 VAE 解码为 6 帧 RGB
6 帧未来画面 训练预测目标	**冻结 VAE → 特征加噪 → 切块 / 嵌入** 切块 = 把特征分组；嵌入 = 把每块映射到共享维度 D		
6 × 3 航点数值 训练预测目标	**数值加噪 → 小型映射网络 MLP** MLP= 全连接映射；每航点 3 维→ D 维，共 6 个		**轨迹输出头 → 6 × 3 更新量** 迭代后得到 6 × 3 的连续航点轨迹
历史 + 真实未来图像 训练几何教师的输入	**冻结 DA3 → 取未来几何特征 → 归一化** DA3： Depth Anything 3 （Lin 等， 2025） 特征加噪 → MLP ； 共 6 个未来几何向量		**几何输出头 → 几何特征更新量** 迭代后恢复未来视角的相机几何特征

VAE： 变分自编码器，编码压缩、解码重建。
来自 Wan （Wang 等， 2025），冻结使用。
向量维度 D： 每个 token 包含 D 个数字。

另加入可学习的寄存向量帮助信息交流；视觉向量保留时空位置编码，其余类型不强加图像网格位置。

参数更新： VAE 与 DA3 冻结；共享网络、新增 MLP 与输出头训练。更新量不是机器人速度。

来源： UniNav §3.2–3.3 ； Wan （2025）； DA3 （2025）。具体压缩尺寸、切块大小、 D 与几何维度未披露。